## Practica Spark y Kafka Streaming

## 1. Código productor:

Los comandos necesarios para ejecutar bin/kafka-console-producer.sh dentro de kafka se han recopilado en el archivo de comandos bdp\_producer.sh, cuyo contenido es el que se muestra a continuación:

```
#Nos trasladamos a la ruta donde esta instalado kafka
cd /home/kafka/kafka 2.11-2.4.0/bin
#Crear el topic
./kafka-topics.sh --create --zookeeper localhost:2181 --replication-
factor 1 --partitions 1 --topic practicaBDP
#Listamos los topics para verificar que el topic fue creado
./kafka-topics.sh --list --zookeeper localhost:2181
#Copiamos el archivo a enviar al productor
cp /home/keepcoding/Descargas/personal.json .
ls
cd ..
#Ejecutar el productor en el topic creado
cat bin/personal.json | bin/kafka-console-producer.sh --broker-list
localhost:9092 --topic practicaBDP
#Codigo para eliminar el topic (no se ejecuta)
#./kafka-topics.sh --zookeeper localhost:2181 --delete --topic
practicaBDP
```

## 2. Código consumidor:

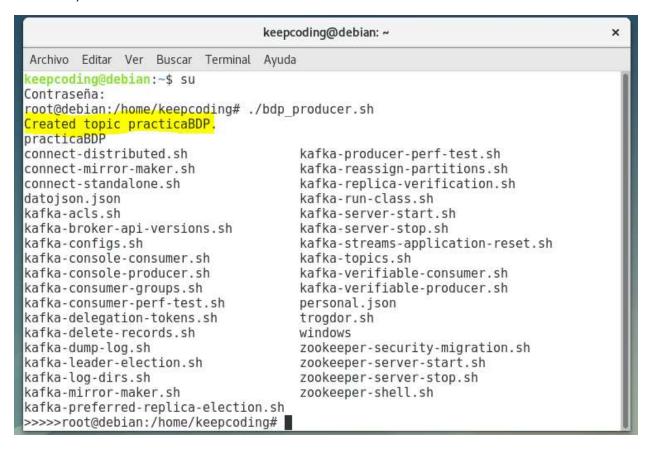
Para verificar que el script del productor ha funcionado, ejecutamos via consola el script bin/kafka-console-consumer.sh, y al igual que se creo un script combinado del productor, tambien tenemos el archivo de comandos bdp consumer.sh con las siguientes intrucciones:

```
#Nos trasladamos a la ruta donde esta instalado kafka

cd /home/kafka/kafka_2.11-2.4.0

#Ejecutar el consumidor para leer el topic creado
bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --
topic practicaBDP --from-beginning
```

Al ejecutar los scripts tanto del productor como del consumidor desde el terminar tenemos estos resultados, los cuales son satisfactorios:



```
keepcoding@debian: ~ x

Archivo Editar Ver Buscar Terminal Ayuda

keepcoding@debian: ~ $ su

Contraseña:
root@debian: /home/keepcoding# ./bdp_consumer.sh
{"id":1,"first_name":"Jeanette","last_name":"Penddreth","email":"jpenddreth0@cen
sus.gov", "gender":"Female", "ip_address":"26.58.193.2"},
{"id":2,"first_name":"Giavani","last_name":"Frediani","email":"gfredianil@senate
.gov", "gender":"Male", "ip_address":"229.179.4.212"},
{"id":3,"first_name":"Noell","last_name":"Bea","email":"nbea2@imageshack.us","ge
nder":"Female","ip_address":"180.66.162.255"},
{"id":4,"first_name":"Willard","last_name":"Valek","email":"wvalek3@vk.com","gen
der":"Male","ip_address":"67.76.188.26"}
```

## Posteriormente, consumimos el archivo desde kafka con el objeto scala Practica ConsumidorJSON.scala:

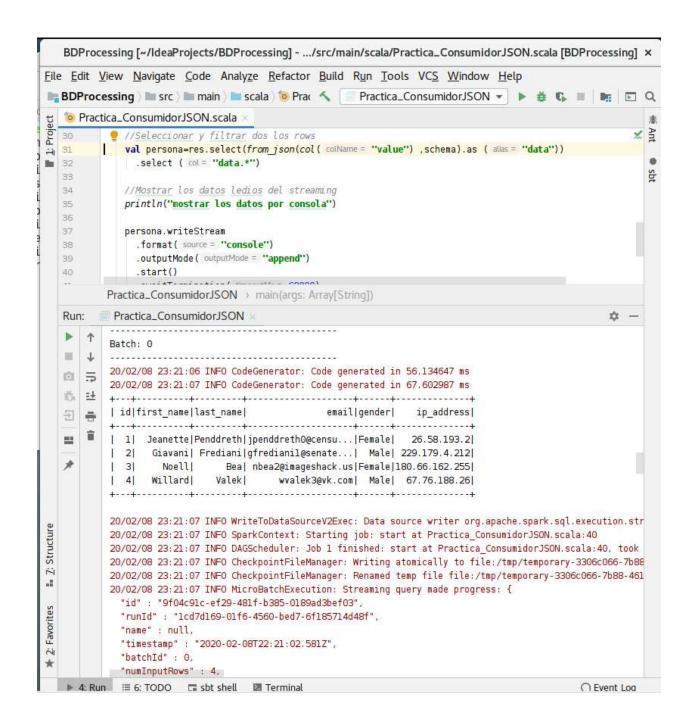
```
import org.apache.spark.sql.SparkSession
import org.apache.spark.sql.types.{IntegerType, StringType, StructType}
import org.apache.spark.sql.functions.{from_json,col}

object Practica_ConsumidorJSON {
    def main(args: Array[String]): Unit = {
        //declarar la app
        val
    spark=SparkSession.builder().appName("JsonKafkaConsumer").master("local").ge
tOrCreate()

//Configurar stream de entrada
    val df=spark.readStream
        .format("kafka")
        .option("kafka.bootstrap.servers", "localhost.localdomain:9092")
        .option("subscribe", "practicaBDP")
        .option("startingOffsets", "earliest")
        .load()
```

```
// castear los datos leidos en formato kafka para convertirlos en
strings
   val res=df.selectExpr("CAST(value AS STRING) as value")
   //Declarar la estructura de los datos
   val schema= new StructType()
      .add("id", IntegerType)
      .add("first name", StringType)
      .add("last_name",StringType)
      .add("email",StringType)
      .add("gender",StringType)
      .add("ip address", StringType)
   //Seleccionar y filtrar dos los rows
   val persona=res.select(from json(col("value") ,schema).as ("data"))
      .select ("data.*")
      .filter("first name not like \"Giavani\"")
      .filter("first name not like \"Noell\"")
   //Mostrar los datos ledios del streaming
   println("mostrar los datos por consola")
   persona.writeStream
      .format("console")
      .outputMode("append")
      .start()
      .awaitTermination(60000)
  }
}
```

Al ejecutar el script sin las sentencias filter podemos ver el contenido del archivo personal.json enviado por el productor



Y finalmente al ejecutar con las sentencias filter excluimos dos registros diferentes segun las indicaciones de la practica:

